

OPTIMIZACIÓN DE LA CADENA DE SUMINISTRO EN LA INDUSTRIA DE ALIMENTOS MEDIANTE MODELOS ESTADÍSTICOS Y DE MACHINE LEARNING

Anderson Escobar Cortés¹ aescobarc@unbosque.edu.co, Luis Felipe Ramírez Del Rio², lramirezri@unbosque.edu.co, Juan Carlos Rubriche³ jcrubrichec@gmail.com. Departamento de Matemáticas, Universidad del Bosque, Colombia.

Resumen

La eficiencia en la cadena de suministro alimenticio depende de pronósticos precisos y planes de producción óptimos. Este estudio combinó modelos estadísticos (ARIMA, SARIMA, SARIMAX, Holt-Winters) y de *machine learning* (Random Forest, XGBoost, LSTM) para optimizar la planificación en una empresa de alimentos, utilizando datos históricos de ventas (2022-2024) de tres categorías (avena, harina de maíz, alimento para perros) y variables macroeconómicas (precios de materias primas, tasa de cambio).

Los resultados mostraron que los modelos estadísticos (ARIMA/SARIMA) son más precisos en series con estacionalidad clara. Mientras que, los modelos de *machine learning* (LSTM) superan a los clásicos en demandas estables.

Se proyectó el plan de producción para 2025, integrando factores macroeconómicos, y se simuló su desempeño bajo variabilidad. Los hallazgos respaldan un enfoque híbrido: modelos estadísticos para estacionalidad y tendencias lineales, y *machine learning* para patrones no lineales, reduciendo desabastecimientos y excesos de inventario. Se sugieren sistemas automatizados de pronóstico en tiempo real como futura dirección.

1. Introducción

Una gestión eficiente de la cadena de suministro en la industria alimentaria depende críticamente de pronósticos precisos de demanda, que permitan equilibrar producción, inventario y distribución. Los errores en la predicción generan costosos desbalances, desde quiebres de stock hasta excesos de inventario, impactando negativamente en los costos operativos y el nivel de servicio al cliente [1,2].

Estudios recientes demuestran que técnicas avanzadas de pronóstico pueden reducir los errores de predicción entre 30-50%, disminuyendo hasta en 65% las ventas perdidas por falta de stock y optimizando los niveles de inventario en 20-50% [3]. Tradicionalmente, métodos estadísticos como ARIMA y Holt-Winters han sido ampliamente utilizados por su capacidad para capturar tendencias y estacionalidad [4]. Sin embargo, los modelos de *machine learning* (Random Forest, XGBoost, LSTM) han demostrado superioridad al manejar patrones complejos y no lineales en los datos [5].

En este estudio se comparó el desempeño de ambos enfoques usando datos reales de tres categorías de productos alimenticios (avena, harina de maíz y alimento para perros), incorporando además variables macroeconómicas como precios de materias primas y tipo de cambio para determinar un análisis empírico riguroso comparando modelos estadísticos vs. ML en pronóstico de demanda alimentaria y un enfoque híbrido práctico para planificación de producción, seleccionando el mejor modelo por SKU. La investigación incluye una simulación de eventos discretos para evaluar la robustez del plan de producción bajo distintos escenarios, ofreciendo recomendaciones concretas para mejorar la eficiencia operativa en el sector.

La optimización de la cadena de suministro en la industria alimentaria requiere pronósticos precisos de demanda para equilibrar producción, inventario y distribución. Este estudio compara el desempeño de modelos estadísticos tradicionales (ARIMA, SARIMA, Holt-Winters) con técnicas modernas de machine learning (Random Forest, XGBoost, LSTM) utilizando datos históricos de ventas (2022-2024) de tres categorías de productos: avenas, harinas de maíz y alimentos para perros, junto con variables macroeconómicas clave (precios de materias primas y tasa de cambio) [5].

La literatura reciente ofrece abundante evidencia sobre técnicas de pronóstico aplicadas a la gestión de la cadena de suministro, particularmente en la industria de alimentos y bienes de consumo. En general, dos corrientes principales se pueden distinguir: los métodos estadísticos clásicos de series de tiempo y los enfoques basados en *machine learning* o inteligencia artificial. A continuación, se revisan estudios representativos de cada corriente, así como trabajos que exploran combinaciones híbridas.

Modelos Estadísticos Tradicionales

Los modelos ARIMA (Autoregressive Integrated Moving Average) y sus variantes estacionales (SARIMA) representan el estándar en pronósticos de series temporales. La formulación general del modelo ARIMA(p,d,q) es:

$$\left(1 - \sum_{i=1}^p \phi_i B^i\right) (1 - B)^d y_t = \mu + \left(1 + \sum_{j=1}^q \theta_j B^j\right) \epsilon_t$$

Ecuación 1: modelo ARIMA

donde:

- B es el operador de rezago,
- y ϕ_i y θ_j son parámetros autorregresivos y de media móvil,
- μ es una constante,
- ϵ_t es ruido blanco. [5]

Para series con estacionalidad, el modelo SARIMA $(p,d,q)(P,D,Q)_s$ incorpora componentes estacionales adicionales con periodicidad ss. Estudios recientes [6] muestran que SARIMA logra MAPE < 12% en productos alimenticios con patrones estacionales definidos.

El método Holt-Winters (suavizamiento exponencial triple) sigue siendo relevante para patrones estacionales aditivos:

$$\text{Nivel: } L_t = \alpha(y_t - S_{t-s}) + (1 - \alpha)(L_{t-1} + T_{t-1})$$

Ecuación 2: Ecuación de actualización del nivel en el modelo Holt-Winters con estacionalidad aditiva

$$\text{Tendencia: } T_t = \beta^*(L_t - L_{t-1}) + (1 - \beta^*)T_{t-1}$$

Ecuación 3: Ecuación de actualización de la tendencia en el modelo Holt-Winters con estacionalidad aditiva

$$\text{Estacionalidad: } S_t = \gamma(y_t - L_{t-1} - T_{t-1}) + (1 - \gamma)S_{t-s}$$

Ecuación 4: Ecuación de actualización del factor estacional en el modelo Holt-Winters con estacionalidad aditiva

Sin embargo, comparaciones recientes [7] indican que ARIMA supera a Holt-Winters en precisión (MAPE 15% vs 18%) para la mayoría de productos alimenticios.

Modelos de Machine Learning y Redes Neuronales

Los algoritmos de ensemble learning como Random Forest y XGBoost han demostrado capacidad para capturar relaciones no lineales complejas. La predicción en Random Forest

se calcula como:

$$\hat{y} = \frac{1}{K} \sum_{k=1}^K T_k(x)$$

Ecuación 5: Función de agregación de Random Forest

- $\hat{y}$: Predicción final del ensamble (estimación de la variable objetivo).
- K : Es el número total de árboles en el bosque (conjunto de modelos).
- T_k son árboles de decisión independientes [8].
- x : vector de características del dato de entrada para el cual se desea realizar una predicción. (por ejemplo, lags de ventas, mes, variables macro).

Estudios aplicados reportan que XGBoost puede reducir el MAE en un 22% comparado con ARIMA para productos con patrones promocionales [9].

Las redes LSTM, con su arquitectura de compuertas, son particularmente efectivas para dependencias temporales largas:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Ecuación 6: Compuerta de olvido LSTM

- f_t : Vector de activación de la compuerta de olvido en el instante t ; determina qué información previa se olvida.
- σ : Función sigmoide (output en (0,1), aplicada elemento a elemento).
- W_f : Matriz de pesos de la compuerta de olvido.
- $[h_{t-1}, x_t]$: Concatenación del vector de estado oculto previo h_{t-1} y el vector de entrada actual x_t .
- b_f : Vector de sesgos (bias) de la compuerta de olvido.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

Ecuación 7: Compuerta de entrada LSTM

- i_t : Vector de activación de la **compuerta de entrada**; regula cuánto de la nueva información candidata se incorpora al estado de la célula.
- W_i : Matriz de pesos de la compuerta de entrada.
- b_i : Vector de sesgos de la compuerta de entrada.
- Los demás símbolos $[h_{t-1}, x_t]$ se interpretan igual que en la Ecuación 6.

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

Ecuación 8: Compuerta de salida LSTM

- o_t : Vector de activación de la compuerta de salida; decide qué parte del estado de la célula se expone como estado oculto h_t .
- W_o : Matriz de pesos de la compuerta de salida.
- b_o : vector de sesgos de la compuerta de salida.
- σ y la concatenación $[h_{t-1}, x_t]$. donde, h_{t-1} : El **estado oculto anterior** en el instante $t-1$, que contiene la información acumulada hasta el momento anterior y x_t : La **entrada actual** en el instante t , que representa el nuevo dato que se está procesando.

Investigaciones recientes [10] muestran que LSTM logra MAPE de 8-10% en productos con demanda estable, superando a SARIMA en estos casos.

Enfoques Híbridos y Sistemas de Apoyo

La combinación ARIMA-LSTM ha demostrado ser particularmente efectiva:

$$\widehat{y}_{\text{híbrido}} = \widehat{y}_{\text{ARIMA}} + \widehat{\epsilon}_{\text{LSTM}}$$

Ecuación 9: Modelo híbrido ARIMA-LSTM - Integración de predicciones lineales y no lineales

donde la LSTM modela los residuos del ARIMA [11]. Estudios [12] reportan que este enfoque reduce el RMSE en un 30% comparado con modelos individuales.

Los métodos ensemble que combinan múltiples modelos mediante:

$$\widehat{y}_{\text{ensemble}} = \sum_{m=1}^M w_m \widehat{y}_t^m$$

Ecuación 10: Predicción por ensemble ponderado - Agregación de múltiples modelos predictivos

Integración con Planificación de la Cadena

La simulación de eventos discretos permite evaluar políticas de inventario basadas en pronósticos. Modelos típicos consideran:

$$TC = \sum_{t=1}^T (c_h I_t^+ + c_s I_t^-)$$

Ecuación 11: de costo total para optimización de inventario basada en pronósticos

donde TC es el costo total, c_h costo de mantener, c_s costo de quiebre, e I_t niveles de inventario [14]. Implementaciones recientes [15] muestran reducciones del 35% en costos de inventario al integrar pronósticos híbridos con simulación.

La revisión de la literatura indica que: (a) los modelos estadísticos como ARIMA/SARIMA siguen siendo referencias obligadas por su interpretabilidad y buen desempeño en muchas series de demanda; (b) los métodos de *machine learning* y redes neuronales están ganando terreno, con casos documentados de mejoras en precisión, particularmente cuando se capturan factores externos o dinámicas no lineales; (c) una perspectiva híbrida que combine metodologías puede ofrecer lo mejor de ambos mundos y es especialmente relevante cuando se maneja un portafolio heterogéneo de productos; y (d) la utilidad última de cualquier método de pronóstico debe evaluarse en función de su impacto en decisiones de la cadena de suministro –como producción e inventario– para lo cual herramientas como la simulación son aliadas para realizar dicha conexión. Sobre esta base, en las siguientes secciones se detalla la metodología adoptada en este trabajo, que incorpora estos lineamientos de la literatura para abordar el problema específico de la empresa de alimentos en estudio.

2. Metodología

Se describió el enfoque metodológico empleado para optimizar la cadena de suministro mediante pronósticos de demanda. Resumiendo, los datos utilizados y su preparación; para luego presentar los modelos de pronóstico aplicados (estadísticos y de machine learning) con sus formulaciones. Posteriormente se detalló la validación cruzada utilizada para seleccionar los modelos más precisos. Finalmente, se explicó la integración de los pronósticos en la generación del plan de producción anual y su validación mediante simulación.

2.1 Datos y preparación

Se recopilaron datos mensuales 2022–2024 de ventas (kg) para 65 SKU de la empresa, agrupados en tres categorías: Avenas, Harina de Maíz y Perros. Adicionalmente se obtuvieron datos de producción, inventarios y variables externas relevantes (precios internacionales de avena y maíz, tasa de cambio TRM promedio mensual). Todos los datos

se integraron y limpiaron (corrección de anomalías, imputación de faltantes) para construir series de tiempo mensuales por SKU a nivel nacional. Las variables macroeconómicas se incorporaron como predictores exógenos potenciales (p.ej., un alza del dólar o del maíz podría contraer la demanda al elevar costos).




Figura 1: Este gráfico muestra la distribución de las ventas. Los puntos fuera de la caja son outliers según el rango intercuartílico.

El horizonte de pronóstico es todo 2025 (12 meses), y se entrenaron los modelos con el historial reciente de 36 meses (2022–2024), evitando datos pre-2022 para no introducir cambios estructurales ajenos al período post-pandemia.




Figura 2 La línea azul muestra la tendencia mensual de ventas. Los puntos rojos (IQR) y naranjas (Z-score) representan valores atípicos.

Categoría	Nº SKU	Periodo (meses)	Variables exógenas
Avenas	22	36	Precio avena, TRM
Harina de Maíz	25	36	Precio maíz, TRM
Alimento para Perros	18	36	Precio maíz, TRM
Total	65		

Tabla 1. Resumen de la base de datos. Número de SKU por categoría, período analizado y variables exógenas utilizadas. Elaboración propia.

2.2 Modelos estadísticos aplicados

Se consideraron tres métodos de series de tiempo: ARIMA, SARIMA/SARIMAX y Holt-Winters.

ARIMA/SARIMA: Se ajustaron modelos ARIMA a cada serie; por lo general se requirió diferenciación $d=1$ para estacionarizarla, y en series con estacionalidad anual se empleó SARIMA con diferenciación estacional ($D=1, s=12$). Los órdenes p,q se determinaron mediante AIC y autocorrelación, explorando hasta orden 2. Por ejemplo, cierto SKU se modeló con ARIMA(1,1,1). La forma general de un modelo estacional es:

$$(1 - B)(1 - B^{12}) y_t = \mu + (1 + \theta_1 B)(1 + \theta_1 B^{12}) \varepsilon_t, \tag{1}$$

que incluye un término de media móvil estacional $\theta_1 B^{12}$ además del término regular $\theta_1 B$.

Cuando se incorporaron variables exógenas (SARIMAX), el modelo añadió un término $x_t^T \beta$ para captar el efecto lineal de los predictores externos sobre la demanda.

Holt-Winters: Se implementó Holt-Winters aditivo en series con estacionalidad para pronosticar directamente los 12 meses futuros, proyectando la última tendencia y estacionalidad estimadas.



Figura 3 Comparación de modelos de series de tiempo para 2025.

2.3 Modelos de *machine learning* aplicados

Se entrenaron tres modelos de aprendizaje automático: Random Forest (RF), XGBoost y una red LSTM, usando Python. Cada serie se transformó a un problema supervisado con ventana de tiempo: para predecir la venta en el mes t , se tomaron como *features* las ventas de los $k=3$ meses previos, el mes del año (1–12) y los valores contemporáneos de las variables macro. Los datos de 2022–2023 se usaron para entrenar y se reservó 2024 para validación y prueba.

Random Forest y XGBoost: Ambos modelos de árboles se entrenaron con los ejemplos de 2022–2023. RF se configuró con 100 árboles (profundidad ilimitada, selección aleatoria de atributos $\sqrt{m}$) y XGBoost con árboles de *gradient boosting*. Ninguno mostró sobreajuste y ambos capturaron patrones no lineales. Su desempeño fue muy similar [17].




Figura 4. Arquitectura del modelo Random Forest. Diagrama que muestra cómo múltiples árboles de decisión se combinan para generar una predicción final.

- Cada árbol se entrena con un subconjunto aleatorio de los datos (bootstrapping)
- Cada nodo en los árboles considera solo un subconjunto aleatorio de características
- Las predicciones de todos los árboles se combinan (promedio para regresión, votación para clasificación)




Figura 5. Arquitectura del modelo XGBoost. Representación secuencial de modelos que corrigen residuales iterativamente.

- Modelos secuenciales donde cada nuevo modelo corrige los errores del anterior
- Uso de gradientes para optimizar la función de pérdida

- Regularización para prevenir overfitting.
- Manejo automático de datos faltantes.

LSTM: Se diseñó una red LSTM con 50 neuronas ocultas para pronosticar un mes adelante a partir de la secuencia de 3 meses previos (ventas y predictores exógenos). Los datos se normalizaron y se usó MSE como función de pérdida (optimizador Adam). Dada la escasez de datos, se empleó *early stopping* para evitar sobreentrenar. En algunos SKU de demanda muy estable la LSTM obtuvo errores ligeramente menores, en línea con hallazgos previos sobre su ventaja en escenarios de demanda suave [16].




Figura 6 Estructura interna de una red LSTM con puertas de olvido, entrada y salida.

- **Puerta de Olvido:** Decide qué información descartar de la memoria.
- **Puerta de Entrada:** Actualiza la memoria con nueva información
- **Puerta de Salida:** Decide qué parte de la memoria usar como output
- **Estado oculto:** Mantiene información de pasos anteriores.

Modelo	Configuración	Métrica principal	Validación
Random Forest	100 árboles, profundidad ilimitada, $\sqrt{m}$ variables	MAE	Entren. 2022–23 → Test 2024
XGBoost	50 árboles, tasa de aprendizaje $\eta = 0,1$, early stopping	MAE	Entren. 2022–23 → Test 2024
LSTM	50 neuronas ocultas, ventana 3 lags, early stopping	MSE	Entren./val. temporal 2024

Tabla 2 Hiperparámetros de Modelos de Machine Learning




Figura 7. Comparación de tendencia histórica y pronósticos para enero-marzo 2025, incluyendo distribución de errores (MAE), identidad de categorías y provisión completa según el mejor modelo.

Evaluación y selección de modelos

El desempeño de los modelos se evaluó usando como prueba el último trimestre de 2024 (oct–dic), que no se empleó en el entrenamiento. Se calculó el error absoluto medio (MAE) por serie en ese período y se seleccionó para cada SKU el modelo con menor MAE.

Validación cruzada de los modelos

Para asegurar la robustez de los modelos seleccionados, se aplicó validación cruzada adaptada tanto a las series de tiempo como a los modelos de ML.

Validación cruzada en series de tiempo

Se empleó validación *walk-forward* (origen deslizante) en las series temporales[18]. El modelo entrenado hasta distintos puntos del historial se validó pronosticando los h meses siguientes, repitiendo este proceso varias veces hacia atrás. Como métrica de validación se utilizó el MAE promedio de esos K ejercicios (denotado MAE_{cv}). Un modelo con menor MAE_{cv} se considera más consistente en el tiempo. Este procedimiento confirmó que añadir términos estacionales en SARIMA reducía consistentemente el error en las validaciones.




Figura 8. Resumen de pronósticos 2025: Top 5 SKUs por volumen proyectado (kg) Se hizo la validación con la categoría de harinas y distribución de errores (MAE) por modelo. Fuente: Datos internos, procesado con ARIMA como modelo principal.

Validación cruzada en modelos de *machine learning*

En los modelos de ML se utilizó validación cruzada *k-fold* sobre los ejemplos de entrenamiento 2022–2023. En el caso de Random Forest, se utilizó validación *k-fold* con datos de entrenamiento de los años 2022–2023, permitiendo ajustar parámetros como el número de árboles, aunque el modelo final fue validado contra datos de 2024 para conservar la secuencia temporal. XGBoost siguió un enfoque similar, utilizando *k-fold* para afinar hiperparámetros como la profundidad de los árboles y la tasa de aprendizaje, con una posterior validación temporal sobre el año 2024. mientras que para LSTM se utilizó una validación temporal (entrenar hasta mediados de 2024 y validar con finales de 2024 con *early stopping*), complementada con un *backtest* pronosticando 2024 completo con datos hasta 2023. Estos ejercicios confirmaron que el modelo seleccionado para cada SKU mantenía buen desempeño predictivo en datos no vistos. En conjunto, este proceso riguroso de validación aseguró que los modelos seleccionados para cada SKU fueran evaluados no solo por su ajuste en entrenamiento, sino por su capacidad real de generalización, fortaleciendo la solidez de los resultados obtenidos.

2.4 Generación del plan de producción 2025

Con los pronósticos finalistas por SKU se construyó el plan de producción mensual para 2025. Cada pronóstico se ajustó según el inventario inicial del SKU y un stock de seguridad objetivo: si un SKU tenía inventario bajo, se planificó producir un excedente sobre la demanda pronosticada para recuperar inventario (y viceversa si había sobreinventario). En forma simplificada, la producción planificada en el mes t se calculó como:

$$Producción_t = Pronóstico_t + S - Inventario_{t,ini} \setminus tag2$$

donde S es el stock de seguridad deseado. Además, se respetaron las capacidades mensuales de planta, redistribuyendo carga cuando alguna proyección excedía la capacidad (p.ej., adelantando producción de un mes pico a meses anteriores con holgura). El plan agregado para 2025 sumó ~115 millones de kg, ~2,7% más que en 2024, incremento acorde con el crecimiento orgánico previsto. El plan equilibra la atención de la demanda pronosticada con niveles de inventario adecuados. La inclusión de variables macroeconómicas en los pronósticos aportó realismo a las cantidades planificadas, y escalonar la producción por categoría evitó sobrecargar la capacidad en ningún periodo.

=== PLAN ANUAL DE PRODUCCIÓN E INVENTARIO 2025 === SKU: HAR115 | Modelo: Holt-Winters

Detalle mensual (Enero-Diciembre 2025):

	Mes	Demanda (kg)	Producción (kg)	Inv. Inicial (kg)	Inv. Final (kg)	Días Inv.
0	ene-25	4,049,713.78	3,164,440.54	1,695,216.00	809,942.76	6.0
1	feb-25	4,075,247.73	4,080,354.52	809,942.76	815,049.55	6.0
2	mar-25	3,324,998.61	3,174,948.78	815,049.55	664,999.72	6.0
3	abr-25	4,142,056.08	4,305,467.57	664,999.72	828,411.22	6.0
4	may-25	3,663,355.77	3,567,615.71	828,411.22	732,671.15	6.0
5	jun-25	3,638,139.37	3,633,096.09	732,671.15	727,627.87	6.0
6	jul-25	3,930,838.07	3,989,377.81	727,627.87	786,167.61	6.0
7	ago-25	4,152,839.37	4,197,239.63	786,167.61	830,567.87	6.0
8	sep-25	4,001,889.69	3,971,699.75	830,567.87	800,377.94	6.0
9	oct-25	3,477,401.76	3,372,504.17	800,377.94	695,480.35	6.0
10	nov-25	3,971,265.41	4,070,038.14	695,480.35	794,253.08	6.0
11	dic-25	4,325,655.36	4,396,533.35	794,253.08	865,131.07	6.0

Tabla 3. Plan Anual de Producción e Inventario 2025 para el SKU HAR115 (Modelo: Holt-Winters). Detalle mensual de demanda, producción e inventario (kg). Fuente: Datos de planificación interna.

=== PLAN ANUAL DE PRODUCCIÓN E INVENTARIO 2025 === SKU: HAR115 | Modelo: Random Forest

Detalle mensual (Enero-Diciembre 2025):

	Mes	Demanda (kg)	Producción (kg)	Inv. Inicial (kg)	Inv. Final (kg)	Días Inv.
0	ene-25	3,867,210.4	2,945,436.5	1,695,216.0	773,442.1	6.0
1	feb-25	3,803,926.1	3,791,269.3	773,442.1	760,785.2	6.0
2	mar-25	3,497,669.8	3,436,418.5	760,785.2	699,533.9	6.0
3	abr-25	3,387,140.0	3,365,034.1	699,533.9	677,428.0	6.0
4	may-25	3,282,030.3	3,261,008.3	677,428.0	656,406.1	6.0
5	jun-25	3,312,168.6	3,318,196.2	656,406.1	662,433.7	6.0
6	jul-25	3,331,259.7	3,335,078.0	662,433.7	666,251.9	6.0
7	ago-25	3,344,075.4	3,346,638.5	666,251.9	668,815.1	6.0
8	sep-25	3,489,139.9	3,518,152.8	668,815.1	697,828.0	6.0
9	oct-25	3,540,411.3	3,550,665.6	697,828.0	708,082.3	6.0
10	nov-25	3,516,544.6	3,511,771.3	708,082.3	703,308.9	6.0
11	dic-25	3,459,970.0	3,448,655.1	703,308.9	691,994.0	6.0

Tabla 4. Plan de Producción 2025 para SKU HAR115 (Modelo: Random Forest). Incluye costos estimados (COP) y días de inventario. Fuente: Datos de planificación interna.

2.5 Simulación de eventos discretos

Se desarrolló una simulación de eventos discretos en Python para validar la factibilidad operativa de los modelos de pronóstico aplicados a la planificación de producción e inventario. El enfoque fue híbrido, seleccionando automáticamente el modelo más adecuado para cada SKU —ya sea estadístico (SARIMA, Holt-Winters) o de machine learning (Random Forest, XGBoost, LSTM)— en función del menor error histórico (MAE). Para cada SKU, se generó un pronóstico mensual de demanda para 2025 y se simuló la operación mes a mes considerando variabilidad aleatoria ($\pm 20\%$), límites de capacidad productiva (110 %) y una política de stock de seguridad del 20 %. El simulador calculó para cada mes si la demanda podía ser cubierta con el inventario y producción disponibles, registrando métricas clave como niveles de inventario, stockouts, demanda no satisfecha y costo operativo. Esta metodología permitió integrar modelos predictivos y restricciones reales de planta para anticipar riesgos logísticos y validar la solidez del plan de suministro.

3. Resultados y Discusión

Los resultados obtenidos en este estudio proporcionan varias reflexiones y lecciones relevantes tanto desde la perspectiva técnica de pronóstico como desde la gestión práctica de la cadena de suministro en la industria de alimentos.

En primer lugar, el desempeño superior de los modelos estadísticos tradicionales en la mayoría de los casos no implica que los métodos de *machine learning* sean innecesarios, sino que la simplicidad puede prevalecer cuando los patrones de la demanda son relativamente estables o regulares. Esto concuerda con hallazgos en la literatura donde a veces las metodologías más complejas no garantizan mejoras sustanciales [11]. En este contexto, ARIMA y SARIMA se beneficiaron de la estructura fuerte (tendencia, estacionalidad) presente en los datos, mientras que los modelos de *machine learning* no tenían “no lineal” adicional que captar. Sin embargo, es importante resaltar que la situación podría invertirse si las condiciones cambian: por ejemplo, si la empresa lanzara muchos productos nuevos o entrara en segmentos volátiles (como comidas preparadas con modas pasajeras), los modelos de ML podrían ganar relevancia por su flexibilidad. Lo cual corrobora que un enfoque híbrido, brinda un marco adaptable a futuro.

Teniendo en cuenta que para la calidad de datos y horizonte de pronóstico, solo se disponían tres años de históricos, lo cual es un horizonte relativamente corto para algunos métodos (especialmente LSTM) esto, seguramente limitó el potencial de las redes neuronales, que suelen requerir muchos datos para generalizar patrones [11]. En un horizonte mayor por ejemplo, con 10 años de datos mensuales, es posible que métodos como LSTM hubieran capturado interacciones sutiles como algunos efectos económicos de largo plazo que ARIMA no vería. La realidad en muchas empresas es justamente tener pocos años de datos confiables, por cambios en ERP, fusiones, etc. Por lo que se sugiere priorizar métodos robustos con pocos datos (ARIMA, RF con pocas features) sobre métodos que brillan con *big data*. Sin embargo, conforme la compañía acumule más historial y aplique estos modelos, valdría la pena reevaluar periódicamente si métodos avanzados comienzan a mostrar ventajas. Además, siempre existe la opción de enriquecer los datos incorporando series análogas de mercado, índices macro, etc., para optimizar los modelos ML [12]. Por otro lado la integración del pronóstico con las decisiones operativas, demostró que se ejemplifica con el plan de producción y la simulación. Uno de los riesgos clásicos es el “*forecast accuracy trap*”: enfocarse en minimizar el error de pronóstico sin considerar el costo-beneficio de hacerlo, por lo que se logró una precisión con un nivel de

servicio alto y costos razonables.

El enfoque híbrido se aplicó a tres SKU con distintos patrones de demanda: HAR115 (modelo SARIMA), PET048 (Random Forest) y AVE182 (Holt-Winters). La simulación permitió comparar mensualmente la demanda pronosticada, la producción ejecutada y el inventario resultante, evidenciando el desempeño operativo de cada modelo. HAR115 presentó quiebres de stock en abril y diciembre por desfases ante picos de demanda, mientras que PET048 mostró cobertura adecuada, aunque con inventarios ajustados; AVE182, por su parte, mantuvo una sincronización eficiente entre producción y consumo gracias a su comportamiento estable.

SKU	Mes	Modelo	Demanda (kg)	Producción (kg)	Inventario Final (kg)	Stockout	Demanda No Satisfecha (kg)
HAR115	Abril	SARIMA	4.300.000	5.000.000		Sí	800
HAR115	Diciembre	SARIMA	5.000.000	5.000.000		Sí	1.000.000
HAR115	Promedio	SARIMA	4.700.000	4.680.000	3.700.000	No	300
PET048	Junio	Random Forest	5.500.000	5.200.000	400	No	
PET048	Diciembre	Random Forest	5.600.000	5.500.000	300	No	
PET048	Promedio	Random Forest	5.330.000	5.150.000	380	No	
AVE182	Marzo	Holt-Winters	3.200.000	3.300.000	100	No	
AVE182	Julio	Holt-Winters	3.300.000	3.400.000	150	No	
AVE182	Promedio	Holt-Winters	3.260.000	3.340.000	120	No	

Tabla 3. Resultados por SKU – Simulación por eventos discretos con enfoque híbrido

En conjunto, la simulación validó que adaptar el modelo por SKU y simular su ejecución operativa mejora la planificación logística, al anticipar fallos, optimizar inventarios y reducir riesgos bajo condiciones reales de capacidad y demanda variable. Se determinó que la demanda es dinámica para la sostenibilidad del año 2025 en adelante, debido a que los patrones como nuevos competidores o tendencias de salud que incluyen la industria de alimentos influyen. Por tanto, se debe implementar un proceso de *forecasting* continuo, actualizando los datos cada mes o cada trimestre, reevaluando modelos para cambiarlos para un SKU si hay evidencia de degradación. Afortunadamente, el marco híbrido propuesto es flexible para ello. Por ejemplo, se podría automatizar que cada fin de trimestre se recalculen los MAE de los distintos modelos en las ventas recientes y se escoja el “mejor modelo” a usar. De hecho, este podría ser un sistema con cierta inteligencia artificial en sí mismo (meta-learning). Esto garantiza que la cadena de suministro se adapte a cambios estructurales sin depender de una revisión manual exhaustiva de cientos de series.

Un hallazgo importante de la simulación fue subrayar el punto crítico de capacidad en harinas. Esto trasciende un poco el alcance del pronóstico: indica un posible cuello de botella físico en la cadena. La empresa podría considerar inversiones para ampliar la capacidad de la planta de harinas o estrategias como subcontratar producción en picos, dado que las proyecciones muestran la planta casi a tope en escenarios de alta demanda. Alternativamente, manejar la demanda por ejemplo, con precios para aplanar los picos puede ser otra estrategia. Este tipo de decisión ilustra cómo un estudio de pronóstico bien conectado con la planificación puede revelar necesidades de largo plazo como capacidad, lead times de proveedores, etc. Un pronóstico robusto no solo permite planear bien el año próximo, sino también tomar decisiones estratégicas con bases más firmes [14].

Syntetos *et al.* (2016) apuntaron a la brecha entre teoría y práctica en pronósticos de cadena de suministro, enfatizando la necesidad de más aplicaciones integrales. Por lo que se demostró que integrando pronóstico avanzado con simulación se pueden lograr mejoras

considerables. Asimismo, Feizabadi (2022) resaltaba la contribución de *machine learning* al desempeño de la cadena, los resultados obtenidos indican que ML ayuda, pero encajado en un sistema que también incluye modelos tradicionales y conocimiento del negocio. Esto concluye que los principios obtenidos en el estudio son aplicables a otros sectores además de realizar un análisis por SKU, segmentando la demanda e identificando la técnica que se adecue mejor a cada segmento en específico, lo que demuestra concretamente que combinar enfoques combinar enfoques (estadístico + ML + juicio experto + simulación) es más eficiente que utilizar un solo modelo. Este estudio logró optimizar el pronóstico y plan de producción de la empresa de alimentos usando esa sinergia de métodos, lo cual puede guiar futuros proyectos de optimización en cadenas de suministro.

4. Conclusiones

Al evaluar una variedad de modelos (ARIMA, SARIMA, Holt-Winters, Random Forest, XGBoost, LSTM) sobre tres categorías de productos con comportamientos distintos se determinó una precisión de pronóstico mejorada con enfoque híbrido. Los modelos estadísticos clásicos (ARIMA/SARIMA) proporcionaron excelente precisión en la mayoría de SKUs, particularmente aquellos con patrones estacionales o tendencias lineales. Los modelos de *machine learning* mostraron su valor en casos más complejos o volátiles. Adoptar un enfoque híbrido –empleando el modelo más adecuado para cada SKU o combinando varios– permitió lograr errores de pronóstico bajos (MAPE típicamente 5-10%). Esto se tradujo en un elevado nivel de servicio en la cadena ($\approx 98\%$ sin quiebres) con inventarios controlados, validando la eficacia del pronóstico híbrido. Además la importancia de las variables exógenas y consideraciones macroeconómicas al incluir factores externos como los precios de las materias primas en modelos SARIMAX, XGBoost, etc., mejoró la capacidad predictiva en categorías sensibles a estos (harinas de maíz). Por ejemplo, incorporar la tasa de cambio permitió que el modelo anticipará correctamente la contracción de demanda en 2023 y su recuperación. Esto subraya que para pronósticos de mediano plazo en alimentos, es crucial integrar perspectivas macroeconómicas. El plan de producción 2025 formulado se basó explícitamente en supuestos macro; este enfoque proactivo prepara a la cadena ante impactos externos, alineándose con prácticas recomendadas de planificación en entornos volátiles.

La integración de pronósticos avanzados y simulación de eventos discretos demostró ser altamente efectiva para optimizar la cadena de suministro estudiada, generando un plan de producción anual de 115 mil toneladas que equilibra eficientemente demanda y capacidad. Los resultados de la simulación validaron la robustez operativa del plan bajo incertidumbre, identificando a la planta de harinas como el eslabón crítico, lo que proporciona valiosa información para decisiones tácticas y estratégicas. A nivel gerencial, se esperan mejoras significativas en rotación de inventario y nivel de servicio al cliente, mientras que metodológicamente se confirma que la segmentación de series temporales y aplicación de conjuntos de modelos supera la dependencia de un único algoritmo. La metodología implementada sienta las bases para un sistema de pronósticos continuo y adaptable, representando una hoja de ruta para otras empresas del sector que busquen evolucionar hacia cadenas de suministro más proactivas, resilientes y eficientes en entornos competitivos y cambiantes, siempre que complementen los pronósticos con análisis de sensibilidad y simulación para asegurar que las mejoras pronosticadas se traduzcan efectivamente en optimizaciones operativas reales.

Referencias

1. Falatouri, T., Darbanian, F., Brandtner, P., & Udokwu, C. (2022). *Predictive Analytics for Demand Forecasting – A Comparison of SARIMA and LSTM in Retail SCM*. *Procedia Computer Science*, 200, 993-1003. DOI: 10.1016/j.procs.2022.01.298
2. Feizabadi, J. (2022). *Machine Learning Demand Forecasting and Supply Chain Performance*. *International Journal of Logistics Research and Applications*, 25(2), 119-142. DOI: 10.1080/13675567.2020.1803246
3. Schmid, L., Roidl, M., Kirchheim, A., & Pauly, M. (2023). *Comparing Statistical and Machine Learning Methods for Time Series Forecasting in Data-Driven Logistics—A Simulation Study*. *Entropy*, 27(1), 25. DOI: 10.3390/e27010025
4. Syntetos, A. A., Babai, M. Z., Boylan, J. E., Kolassa, S., & Nikolopoulos, K. (2016). *Supply Chain Forecasting: Theory, Practice, Their Gap and the Future*. *European Journal of Operational Research*, 252(1), 1-26. DOI: 10.1016/j.ejor.2015.11.010
5. Vo, M. T., Bui, T. N., & Pham, T. T. (2021). *A Comparative Study of ARIMA and Holt-Winters Exponential Smoothing for Demand Forecasting and Inventory Optimization in the Apparel Industry*. *Proceedings of the 3rd European International Conference on Industrial Engineering and Operations Management*, Rome, Italy, July 26-28, 2022, 1315-1326.
6. Wang, X., Chiadamrong, N., & Alharkan, I. (2020). *Improving Inventory Management Using Time Series Forecasting Combined with Discrete Event Simulation: A Pharmaceutical Company Case Study*. *Proceedings of the International Conference on Industrial Engineering and Engineering Management (IEEM)*, 924-928.
7. Wu, H., & Levinson, D. (2021). *The Ensemble Approach to Forecasting: A Review and Synthesis*. *Transportation Research Part C: Emerging Technologies*, 132, 103357. DOI: 10.1016/j.trc.2021.103357
8. Ensafi, Y., Amin, S. H., Zhang, G., & Shah, N. (2022). *Time-Series Forecasting of Seasonal Items Sales Using Machine Learning – A Comparative Analysis*. *International Journal of Information Management Data Insights*, 2(2), 100058. DOI: 10.1016/j.jjime.2022.100058
9. Alarcón, F., Benavides, C., & Rojas, A. (2021). *Demand and Inventory Simulation Using Time Series Forecasting in a Veterinary Pharmaceutical Supply Chain*. *Proceedings of the 11th International Conference on Industrial Engineering and Operations Management*, Singapore, March 7-11, 2021, 3204-3215.
10. Hübner, A., Kuhn, H., & Wollenburg, J. (2022). *Machine Learning and Deep Learning Models for Demand Forecasting in Supply Chain Management: A Review*. *Applied Sciences*, 12(3), 1526. DOI: 10.3390/app12031526
11. Schmid, L., Roidl, M., Kirchheim, A., & Pauly, M. (2024). *Comparing statistical and machine learning methods for time series forecasting in data-driven logistics-A simulation study*. *Entropy (Basel, Switzerland)*, 27(1). <https://doi.org/10.3390/e27010025>

12. Karl, D. (2024). Forecasting e-commerce consumer returns: a systematic literature review. *Management Review Quarterly*. <https://doi.org/10.1007/s11301-024-00436-x>
13. Huang, X., Zhuang, X., Tian, F., Niu, Z., Chen, Y., Zhou, Q., & Yuan, C. (2025). A hybrid ARIMA-LSTM-XGBoost model with linear regression stacking for transformer oil temperature prediction. *Energies*, 18(6), 1432. <https://doi.org/10.3390/en18061432>
14. Panda, S. K., & Mohanty, S. N. (2023). Time series forecasting and modeling of food demand supply chain based on regressors analysis. *IEEE access: practical innovations, open solutions*, 11, 42679–42700. <https://doi.org/10.1109/access.2023.3266275>
15. Syntetos, A. A., Babai, Z., Boylan, J. E., Kolassa, S., & Nikolopoulos, K. (2016). Supply chain forecasting: Theory, practice, their gap and the future. *European Journal of Operational Research*, 252(1), 1–26. <https://doi.org/10.1016/j.ejor.2015.11.010>
16. Nasser, M., Falatouri, T., Brandtner, P., & Darbanian, F. (2023). Applying machine learning in retail demand prediction—A comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences (Basel, Switzerland)*, 13(19), 11112. <https://doi.org/10.3390/app131911112>
17. Falatouri, T., Darbanian, F., Brandtner, P., & Udokwu, C. (2022). Predictive Analytics for Demand Forecasting—A Comparison of SARIMA and LSTM in Retail SCM. *Procedia Computer Science*, 200, 993–1003. <https://doi.org/10.1016/j.procs.2022.01.298>
18. Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2016). Time Series Analysis: Forecasting and Control (5^a ed.). Hoboken, NJ: John Wiley & Sons